UNIVERSIDAD DE GUADALAJARA

CENTRO UNIVERSITARIO DE CIENCIAS ECONÓMICO ADMINISTRATIVAS

MAESTRÍA EN CIENCIA DE LOS DATOS

Alumno: Sergio Delgadillo Domínguez.
Materia: Programación I.
Tarea: Reporte Actividad Cadenas.
Fecha: 12 de octubre de 2026
Correo: sergio.delgadillo7502@alumnos.udg.mx

CUCEA
El mejor lugar para el talento

MCD | MAESTRÍA EN CIENCIA DE LOS DATOS

Reporte Actividad Cadenas.

Introducción

En esta actividad trabajé con un archivo de solicitudes que incluía variaciones en etiquetas, errores de captura y líneas incompletas. Después de implementar el depurador y revisar los resultados, analicé cómo las decisiones de normalización, validación y persistencia afectan la interpretación de los datos. Este informe presenta las respuestas solicitadas, basadas en los resultados obtenidos durante la ejecución del programa.

1. Cambios en la distribución sin normalizar las etiquetas

En el archivo original aparecían varias formas de escribir la misma categoría. Por ejemplo:

-"pago-en-linea"
-"pago_en_linea"
-"Pago en línea"
-"pago en linea"

Si estas etiquetas se contaran sin normalizar, cada variante se convertiría en una categoría distinta. Esto fragmentaría la distribución y daría la impresión de que existen más categorías de las que realmente hay.

Después de normalizar, las 9 etiquetas originales se redujeron a solo 3 categorías reales:

-acceso
-pago_en_línea
-soporte_técnico

La normalización evita interpretaciones equivocadas y permite que la distribución refleje la estructura real del problema. Sin normalizar, la frecuencia de cada categoría estaría dispersa y sería difícil identificar patrones.

2. Sesgo al eliminar todos los rechazos

En mi ejecución obtuve:

-24 registros válidos
-6 rechazados
-tasa de rechazo del 20%

Si se eliminaran los rechazos y solo se analizarán los válidos, se introduciría un sesgo de supervivencia. Esto significa que solo se estudian los registros que "pasaron el filtro", ignorando los que fallaron por errores de captura.

Los rechazos contienen información importante sobre:

-correos mal escritos
-ID’s duplicados
-categorías vacías
-descripciones incompletas

Si se ignoran, se pierde la oportunidad de detectar problemas en el proceso de captura o en el sistema que genera los datos. Los rechazos también muestran patrones de error que pueden ser relevantes para mejorar la calidad del dato.

3. Por qué la tasa de aceptación no demuestra exactitud

La tasa de aceptación solo indica cuántos registros cumplen las reglas mínimas del depurador. En mi caso fue del 80%. Sin embargo, esto no significa que los datos sean exactos o correctos.
Un registro puede ser "válido" y aun así contener información incorrecta. Por ejemplo:

-un correo puede tener formato correcto pero no existir
-una descripción puede ser demasiado vaga
-un ID puede estar bien formado pero asignado incorrectamente

La exactitud requiere validaciones más profundas que las sintácticas. Por eso la tasa de aceptación no es un indicador de calidad del dato, solo de conformidad con las reglas.

4. Información que se pierde con cada transformación

Cada paso del depurador elimina parte del contenido original:

-Normalización de categoría: se pierden mayúsculas, guiones y estilo original.
-Limpieza de descripción: se pierden espacios que podrían indicar errores de captura o patrones de escritura.
-Rechazos: aunque se guardan en JSONL, ya no forman parte del dataset principal.
-Unión de palabras: se pierde la forma original en que el usuario escribió la etiqueta.

Estas pérdidas son normales en procesos de limpieza, pero es importante reconocer que cada transformación reduce la riqueza del dato.

5. Qué ocurre si una descripción contiene "|"

El depurador usa "|" como separador. Si una descripción incluye ese carácter, la línea se dividiría en más de cuatro campos y el registro se rechazaría por "Número incorrecto de campos".
Esto puede ocurrir en sistemas reales donde los usuarios escriben cualquier cosa en la descripción. Para evitarlo, sería necesario usar un formato más robusto como CSV con comillas o JSON por línea, o escapar el separador dentro del texto.

6. Qué cambiar si el archivo supera la memoria disponible

El depurador ya procesa línea por línea, lo cual es adecuado para archivos grandes. Sin embargo, hay riesgos:

-el conjunto de ID’s (id’s_vistos) puede crecer demasiado si hay millones de registros
-el diccionario de categorías también puede crecer si las etiquetas no están normalizadas
-el archivo de rechazos puede volverse muy grande

Si el archivo fuera demasiado grande, sería necesario procesar por bloques, usar almacenamiento temporal en disco o migrar a herramientas diseñadas para datos masivos.

Conclusión

El ejercicio muestra que depurar datos no es solo limpiar texto: también implica tomar decisiones que afectan la interpretación y la calidad del dataset. Normalizar ayuda a evitar distribuciones engañosas, pero también elimina detalles. Rechazar líneas mejora la consistencia, pero introduce sesgos si se ignoran los errores. La tasa de aceptación no garantiza exactitud, y los formatos simples como texto con separadores tienen limitaciones cuando los datos crecen o contienen caracteres especiales.
En resumen, la depuración es necesaria, pero siempre debe hacerse entendiendo qué se gana y qué se pierde en cada paso.